

Diagnóstico de Cáncer de Mama

Análisis Predictivo mediante Machine Learning y Deep Learning

Sebastián Andrés Baldovino – 2243565


Juan José Espinosa – 2243551

El Conjunto de Datos

Wisconsin Diagnostic Dataset

Características computarizadas a partir de imágenes digitalizadas de una aspiración con aguja fina (FNA) de una masa mamaria.

- ✓ 569 muestras de núcleos celulares.
- ✓ 30 características predictivas.
- ✓ Variable objetivo binaria: Maligno (1) / Benigno (0).



Procesamiento de Datos



Limpieza

Eliminación de identificadores irrelevantes (ID) y columnas con valores nulos (Unnamed: 32).



Codificación

Mapeo de la variable objetivo: 'M' (Maligno) a 1 y 'B' (Benigno) a 0 para el procesamiento algorítmico.



Detección de Atípicos

Uso del método de Rango Intercuartílico (IQR) para identificar variaciones extremas en las métricas nucleares.



ANÁLISIS EXPLORATORIO

Descubriendo patrones y relaciones en los datos



Hallazgos del Análisis

- ✓ **Distribución de Clases:** El conjunto cuenta con un 62.7% de casos benignos y un 37.3% malignos.
- ✓ **Correlaciones Fuertes:** Existe una redundancia lineal casi perfecta entre el radio, el perímetro y el área media de las células.
- ✓ **Variabilidad:** Las características "Worst" presentan una mayor dispersión, siendo críticas para detectar la malignidad.

Frecuencia de Diagnósticos

Benigno


357

Maligno

212

Métricas de Aprendizaje Automático

Precisión media obtenida mediante validación cruzada (CV=10):




Nota: El modelo Random Forest demuestra la mayor robustez frente a la variabilidad del conjunto.

Excelencia con Random Forest

Importancia de Características

El algoritmo de bosque aleatorio permite jerarquizar las variables más influyentes:

- ✓ Concave points (worst y mean).
- ✓ Perimeter (worst).
- ✓ Radius (worst).
- ✓ Area (worst).





DEEP LEARNING

Redes Neuronales Artificiales para clasificación compleja

Arquitecturas Evaluadas

01

Red de 3 Capas

Nodos: 64, 128, 128.

Enfoque: Clasificación directa
con capas densas estándar.

02

Red de 6 Capas

Nodos: 64, 64, 128, 128, 256, 256.

Enfoque: Mayor profundidad
para capturar abstracciones
sutiles.

03

Red de 10 Capas

Nodos: 128 en cada capa.


Enfoque: Arquitectura profunda
para análisis de alta complejidad.

Rendimiento en DL

Convergencia de Modelos

Las redes de 3 y 6 capas alcanzaron rápidamente una precisión del 97.37%, demostrando que no siempre es necesaria una profundidad extrema para este tipo de datos tabulares.

El uso de la función de activación ReLU y el optimizador Adam permitió una convergencia estable en menos de 50 épocas.




Reducción de Dimensiones (PCA)

Análisis no Supervisado

La proyección a 2 Componentes Principales captura el 63.24% de la varianza total, permitiendo visualizar la separación natural entre clases.

- ✓ **K-Means:** Logra una agrupación que coincide fielmente con las etiquetas diagnósticas reales.
- ✓ **DBSCAN:** Identifica eficazmente los núcleos densos de la población celular.



Gracias